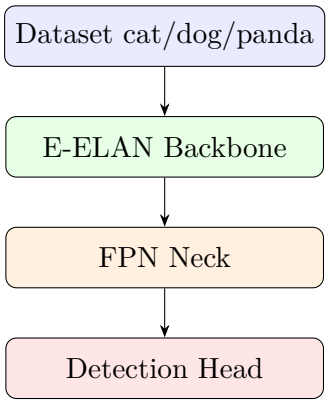
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA TOÁN CƠ TIN HỌC

BÁO CÁO PROJECT

NGHIÊN CỨU VÀ TRIỂN KHAI KHỐI E-ELAN CHO PHÂN LOẠI ẢNH VÀ PHÁT HIỆN ĐỐI TƯỢNG



Sinh viên: NGUYỄN ANH ĐỨC

Mã sinh viên: 23001865

Lớp học phần: MỘT SỐ VẤN ĐỀ CHỌN LỌC VỀ THỊ GIÁC MÁY TÍNH

Giảng viên: CAO VĂN CHUNG

Tháng 10 năm 2026

Mục lục

1 Đặt vấn đề **1**
1.1 Mục tiêu 1

2 Cơ sở lý thuyết **1**
2.1 Mạng tích chập 1
2.2 Tư tưởng ELAN và E-ELAN 2
2.3 Backbone, Neck và Detection Head 2

3 Phương pháp và kiến trúc đề xuất **2**
3.1 Quy trình tổng thể 2
3.2 Dữ liệu 3
3.3 Kiến trúc Backbone 3
3.4 FPN Neck 4
3.5 Detection Head và hàm mất mát 4
3.6 Inference và đánh giá 4

4 Thực nghiệm **5**
4.1 Thiết lập 5
4.2 Kết quả classification 5
4.3 Kiểm tra overfit detection 6
4.4 Kết quả detection 6

5 Đánh giá và nhận xét **7**
5.1 Ưu điểm 7
5.2 Hạn chế 7
5.3 Hướng cải thiện 8

6 Kết luận **8**

7 Tài liệu tham khảo **8**

1 Đặt vấn đề

Trong các hệ thống thị giác máy tính hiện đại, mạng nơ-ron tích chập đóng vai trò quan trọng trong việc trích xuất đặc trưng từ ảnh. Với bài toán phân loại ảnh, mô hình cần ánh xạ toàn bộ ảnh vào một nhãn lớp. Với bài toán phát hiện đối tượng, mô hình đồng thời phải xác định lớp và vị trí của từng đối tượng thông qua bounding box. Hai bài toán có yêu cầu đầu ra khác nhau nhưng có thể dùng chung một mạng trích xuất đặc trưng.

E-ELAN (Extended Efficient Layer Aggregation Network) là một ý tưởng kiến trúc được sử dụng trong họ mô hình YOLOv7. E-ELAN kế thừa tư tưởng mở rộng, kết hợp và trộn đặc trưng của ELAN, nhằm tăng khả năng học đặc trưng mà vẫn kiểm soát chi phí tính toán. Trong phạm vi mini project, mục tiêu không phải sao chép toàn bộ YOLOv7 mà là xây dựng một phiên bản có cấu trúc rõ ràng để khảo sát vai trò của E-ELAN.

Project được triển khai theo hai phần. Phần thứ nhất xây dựng mô hình phân loại ba lớp *cat*, *dog* và *panda*, đồng thời thực hiện lưu trọng số, inference và đánh giá bằng các độ đo phân loại. Phần thứ hai sử dụng E-ELAN làm Backbone, kết hợp FPN Neck và Detection Head một-scale để tạo detector YOLO-style tối giản. Detector được huấn luyện trên dữ liệu có bounding box và đánh giá bằng precision, recall, F1-score và mAP@50.

1.1 Mục tiêu

- Phân tích cấu trúc và nguyên lý hoạt động của khối E-ELAN.
- Xây dựng mô hình phân loại ảnh ba lớp dựa trên E-ELAN.
- Xây dựng detector gồm Backbone, Neck và Head.
- Chuẩn hóa dữ liệu, tổ chức quy trình train, lưu weights và inference.
- Đánh giá kết quả, phân tích hiện tượng overfitting và các giới hạn của kiến trúc.

2 Cơ sở lý thuyết

2.1 Mạng tích chập

Mạng tích chập gồm các lớp convolution, normalization và hàm kích hoạt. Lớp convolution học các bộ lọc để phát hiện cạnh, góc, họa tiết và các cấu trúc có mức độ phức tạp tăng dần. Batch Normalization giúp ổn định phân phối kích hoạt, trong khi SiLU cung cấp hàm kích hoạt trơn, thường phù hợp với các mô hình thị giác hiện đại.

2.2 Tư tưởng ELAN và E-ELAN

ELAN tổ chức nhiều nhánh xử lý với độ sâu khác nhau, sau đó ghép các đặc trưng để tăng đa dạng đường truyền gradient. E-ELAN mở rộng ý tưởng này bằng cách duy trì khả năng học của các nhóm đặc trưng, kết hợp các nhánh song song và thực hiện channel shuffle để trao đổi thông tin giữa các nhóm.

Một block E-ELAN rút gọn trong project gồm các thành phần:

1. Nhánh mở rộng kênh bằng convolution 1×1 có group.
2. Tách tensor thành các nhóm kênh.
3. Các nhánh song song gồm identity, một convolution 3×3 và chuỗi convolution sâu hơn.
4. Ghép các nhánh theo chiều kênh.
5. Trộn kênh và chiếu về số kênh ban đầu.
6. Kết nối residual giữa đầu vào và đầu ra.

Nếu đầu vào của block là X, phép biến đổi có thể mô tả khái quát:

$$Y = X + \mathcal{P}\left(\text{Concat}\left(B_1(G(X)), B_2(G(X)), B_3(G(X))\right)\right),$$

trong đó G là phép mở rộng theo nhóm, B_i là các nhánh xử lý, còn $\mathcal{P}$ là phép chiếu sau khi ghép.

2.3 Backbone, Neck và Detection Head

Backbone chịu trách nhiệm trích xuất đặc trưng. Neck kết hợp các đặc trưng ở những mức phân giải khác nhau, giúp detector sử dụng được cả thông tin ngữ nghĩa cấp cao và thông tin không gian. Detection Head chuyển đặc trưng thành dự đoán bounding box, objectness và xác suất lớp.

Trong project, Backbone tạo ra ba mức đặc trưng tương ứng với các tầng $P3$, $P4$ và $P5$. FPN Neck chiếu đặc trưng $P5$ về số kênh phù hợp, nội suy lên kích thước của $P4$ và cộng với $P4$. Head một-scale dự đoán trên bản đồ lưới 32×32. Mỗi ô lưới chứa bốn giá trị hộp, một objectness và ba điểm lớp.

3 Phương pháp và kiến trúc đề xuất

3.1 Quy trình tổng thể

Quy trình thực nghiệm gồm các bước:

1. Chuẩn hóa dữ liệu phân loại và phát hiện.
2. Kiểm tra ảnh, nhãn, bounding box và phân chia train/validation/test.
3. Xây dựng các module convolution, E-ELAN, Backbone, Neck và Head.
4. Kiểm tra forward pass và loss trên một batch.
5. Overfit trên một tập con nhỏ để xác nhận pipeline học được.
6. Train đầy đủ, lưu checkpoint có validation loss thấp nhất.
7. Decode dự đoán, lọc confidence, NMS và đánh giá trên test set.

3.2 Dữ liệu

Nhãn được thống nhất thành:

$$0 = \text{cat}, \qquad 1 = \text{dog}, \qquad 2 = \text{panda}.$$

Đối với classification, dữ liệu được tổ chức theo cấu trúc thư mục của ImageFolder. Đối với detection, dữ liệu sử dụng định dạng YOLO, trong đó mỗi dòng có dạng (c, x_c, y_c, w, h) và các tọa độ được chuẩn hóa về đoạn $[0, 1]$.

Bảng 1: Thống kê dataset detection

Split	**Ảnh**	**Nhãn**	**Bounding box**
Train	3108	3108	3921
Validation	583	583	703
Test	500	500	629
Tổng	4191	4191	5253

3.3 Kiến trúc Backbone

Ảnh đầu vào có kích thước 256×256. Stem giảm kích thước không gian và tăng số kênh. Các stage tiếp theo lần lượt giảm độ phân giải, tăng số kênh và áp dụng E-ELAN block. Cấu trúc khái quát:

Bảng 2: Các mức đặc trưng của Backbone

Mức	Độ phân giải tương đối	Số kênh	Vai trò
Stem	1/2	32	Đặc trưng ban đầu
$P3$	1/4	64	Chi tiết không gian
$P4$	1/8	128	Đặc trưng trung gian
$P5$	1/16	256	Ngữ nghĩa cấp cao

3.4 FPN Neck

FPN Neck dùng phép chiếu 1×1 cho $P5$ và $P4$, nội suy $P5$ lên cùng kích thước với $P4$, sau đó cộng hai tensor. Một convolution 3×3 được dùng để trộn đặc trưng sau khi hợp nhất. Cách thiết kế này đơn giản nhưng minh họa được vai trò của Neck trong việc truyền thông tin từ tầng sâu về tầng có độ phân giải cao hơn.

3.5 Detection Head và hàm mất mát

Detection Head tạo tensor có kích thước:

$$B \times (5 + C) \times S \times S = B \times 8 \times 32 \times 32,$$

với $C = 3$ lớp. Bốn kênh đầu mô tả vị trí và kích thước hộp, kênh thứ năm là objectness, ba kênh còn lại là điểm lớp.

Target được mã hóa vào ô lưới chứa tâm bounding box. Hàm mất mát gồm ba nhóm chính: Smooth L1 cho hộp, binary cross entropy cho objectness và binary cross entropy cho class score. Objectness ở các ô không có đối tượng được phạt để giảm dự đoán nền.

3.6 Inference và đánh giá

Trong inference, đầu ra raw được chuyển thành tâm và kích thước bounding box, sau đó đưa về hệ tọa độ chuẩn hóa. Confidence được tính bằng tích giữa objectness và điểm lớp lớn nhất. Các dự đoán dưới ngưỡng confidence bị loại. Non-Maximum Suppression được áp dụng riêng theo từng lớp để loại các hộp chồng lấn.

Với một dự đoán và một ground truth, IoU được tính:

$$\text{IoU} = \frac{\text{Area}(B_p \cap B_g)}{\text{Area}(B_p \cup B_g)}.$$

Một dự đoán được xem là đúng khi cùng lớp và IoU không nhỏ hơn 0.5.

4 Thực nghiệm

4.1 Thiết lập

Thực nghiệm được chạy trên Windows với Python 3.13.14, PyTorch 2.12.0, torchvision 0.27.0, ảnh resize về 256×256, optimizer AdamW và batch size 16. Classification sử dụng dataset crop theo ba thư mục lớp. Detection sử dụng dataset YOLO đã chuẩn hóa.

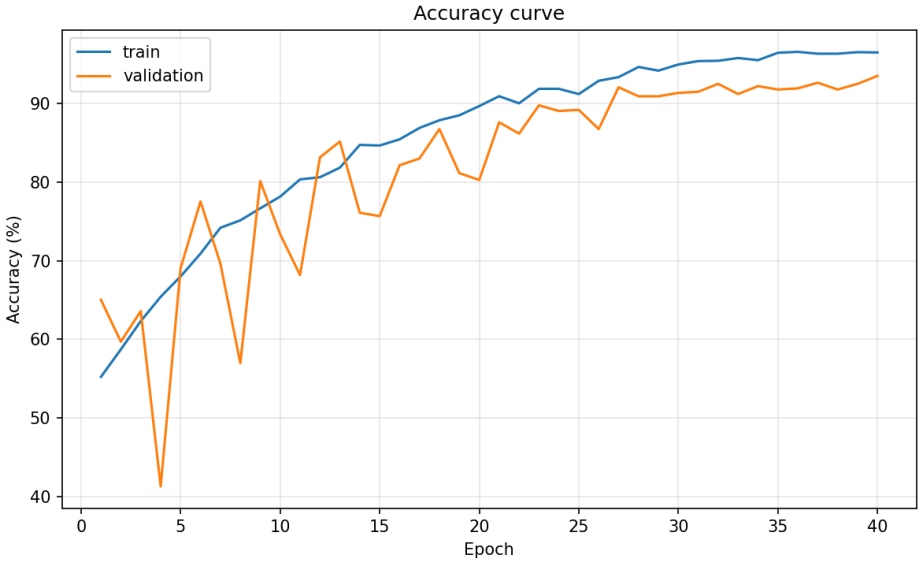
4.2 Kết quả classification

Mô hình classification đạt accuracy trên test khoảng 91,12%. Kết quả theo lớp:

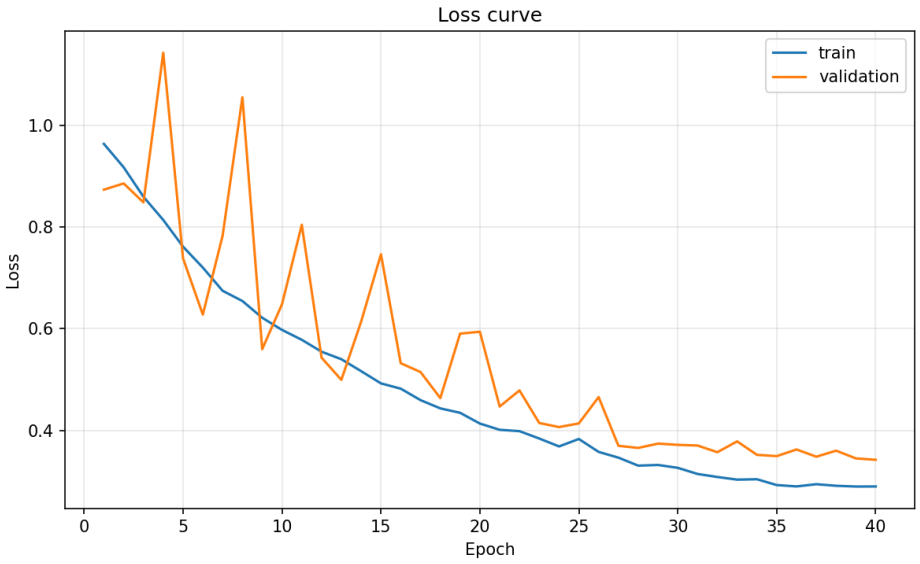
Bảng 3: Kết quả classification trên tập test

Lớp	**Precision**	**Recall**	**F1-score**
Cat	77,78%	96,55%	86,15%
Dog	97,18%	89,15%	92,99%
Panda	89,17%	92,24%	90,68%

Kết quả cho thấy mô hình nhận diện dog tốt nhất về precision. Cat có recall cao, nghĩa là phần lớn ảnh cat được phát hiện đúng nhưng vẫn có một số ảnh lớp khác bị dự đoán nhầm thành cat. Panda đạt kết quả cân bằng hơn giữa precision và recall.



Hình 1: Đường cong accuracy trong quá trình huấn luyện classification



Hình 2: Đường cong loss trong quá trình huấn luyện classification

4.3 Kiểm tra overfit detection

Trên 10 ảnh, loss giảm từ $1,7981$ xuống $0,0091$. Đây là kiểm tra quan trọng để xác nhận target encoding, forward pass, gradient và optimizer hoạt động. Kết quả không đại diện cho khả năng tổng quát hóa nhưng chứng minh pipeline có thể học dữ liệu.

4.4 Kết quả detection

Detection được train 15 epoch với learning rate 3×10^{-4} và weight decay 10^{-4}. Validation loss tốt nhất ở epoch 2:

Bảng 4: Một số mốc validation loss

Epoch	Train loss	Validation loss
1	0,9952	1,0135
2	0,6872	0,8600
5	0,3129	0,9791
10	0,1338	1,8745
15	0,0976	2,3942

Checkpoint tốt nhất được lựa chọn theo validation loss thay vì sử dụng checkpoint cuối. Cách chọn này hạn chế ảnh hưởng của overfitting.

Đánh giá cuối dùng confidence threshold $0,75$, IoU threshold $0,50$ và tối đa 20 detection trên mỗi ảnh:

Bảng 5: Kết quả detection trên tập test

Độ đo	**Giá trị**
Precision	4,83%
Recall	22,58%
F1-score	7,95%
mAP@50	11,63%
True Positive	142
False Positive	2800
False Negative	487

Bảng 6: AP@50 theo lớp

Lớp	**AP@50**
Cat	0,2178
Dog	0,0909
Panda	0,0402

5 Đánh giá và nhận xét

5.1 Ưu điểm

- Pipeline được xây dựng xuyên suốt từ dữ liệu đến inference.
- E-ELAN được tách thành block riêng, dễ phân tích và tái sử dụng.
- Có sự phân tách rõ giữa Backbone, Neck và Head.
- Có checkpoint tốt nhất, biểu đồ loss và các độ đo định lượng.
- Classification cho kết quả tốt, accuracy vượt 90%.
- Quy trình overfit giúp phát hiện sớm lỗi trong target hoặc loss.

5.2 Hạn chế

Kết quả detection thấp hơn classification đáng kể. Precision chỉ đạt $4,83\%$ và mAP@50 đạt $11,63\%$. Nguyên nhân chính là detector đang ở mức tối giản: chỉ dự đoán một-scale, mỗi ô lưới chỉ mã hóa một object, Head không có đầy đủ cơ chế anchor hoặc multi-scale như các detector hiện đại, và hàm mất mát chưa bao gồm các thành phần IoU nâng cao như GIoU hoặc CIoU.

Validation loss tăng sau epoch 2 trong khi train loss tiếp tục giảm, cho thấy overfitting. Dữ liệu panda cũng có AP thấp nhất, gợi ý cần kiểm tra thêm độ đa dạng, chất lượng annotation và cân bằng dữ liệu của lớp này.

Metric mAP@50 trong notebook là metric tự cài đặt nhằm minh họa quy trình. Nó không nên được diễn giải là COCO mAP chuẩn. Khi so sánh nghiêm túc, cần dùng một thư viện đánh giá chuẩn và định dạng kết quả tương ứng.

5.3 Hướng cải thiện

1. Sử dụng multi-scale detection head để xử lý đối tượng lớn nhỏ khác nhau.
2. Cho phép nhiều prediction trên một ô lưới hoặc chuyển sang thiết kế anchor-free đầy đủ.
3. Bổ sung GIoU/CIoU loss, focal loss và cơ chế cân bằng objectness.
4. Tăng cường dữ liệu bằng lật ảnh, biến đổi màu và biến đổi hình học có kiểm soát.
5. Dùng learning-rate scheduler và early stopping dựa trên validation metric.
6. Chuẩn hóa đánh giá bằng COCO API hoặc TorchMetrics.
7. Kiểm tra riêng annotation và chất lượng ảnh của lớp panda.

6 Kết luận

Project đã xây dựng được một quy trình hoàn chỉnh để nghiên cứu E-ELAN cho hai bài toán phân loại ảnh và phát hiện đối tượng. Ở phần classification, E-ELAN cho kết quả tốt với accuracy test khoảng 91,12%. Ở phần detection, E-ELAN được sử dụng làm Backbone và kết hợp với FPN Neck cùng Detection Head một-scale. Pipeline đã thực hiện được train, lưu checkpoint, decode, NMS và đánh giá.

Kết quả detection còn thấp nhưng phù hợp với mục tiêu minh họa một detector tự xây dựng và giúp chỉ ra rõ tác động của thiết kế Backbone–Neck–Head, target encoding và lựa chọn ngưỡng inference. Các hạn chế đã được xác định cụ thể, tạo cơ sở cho các hướng phát triển tiếp theo.

7 Tài liệu tham khảo

1. C.-Y. Wang và cộng sự, "YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors," arXiv:2207.02696, 2022.
2. T.-Y. Lin và cộng sự, "Feature Pyramid Networks for Object Detection," Proceedings of CVPR, 2017.

3. K. He và cộng sự, “Deep Residual Learning for Image Recognition,” Proceedings of CVPR, 2016.

4. J. Redmon và cộng sự, “You Only Look Once: Unified, Real-Time Object Detection,” Proceedings of CVPR, 2016.

5. A. Paszke và cộng sự, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” Advances in Neural Information Processing Systems, 2019.

6. Tài liệu môn học và file *Advanced_CV.pdf* được cung cấp trong project.

7. Tài liệu chính thức của torchvision về transforms, dataset và object detection operators.